

# AI THE FUTURE

## RECONSTRUCCIÓN DE IMÁGENES RADIOGRÁFICAS MEDIANTE APRENDIZAJE PROFUNDO PARA UN DIAGNÓSTICO MÉDICO MEJORADO

PROYECTO FINAL DEL  
CURSO DE DL, ITAM



# Objetivo

**Mejorar la calidad de  
radiografías distorsionadas.**



# Contexto

## Principales causas

Radiación  
dispersa

Mala calidad  
del equipo

Movimiento  
del paciente

Errores de  
procesamiento

# Justificación



Mejores diagnósticos y tratamientos



Reducción repetición de estudios = ahorros



Menor exposición a radiación



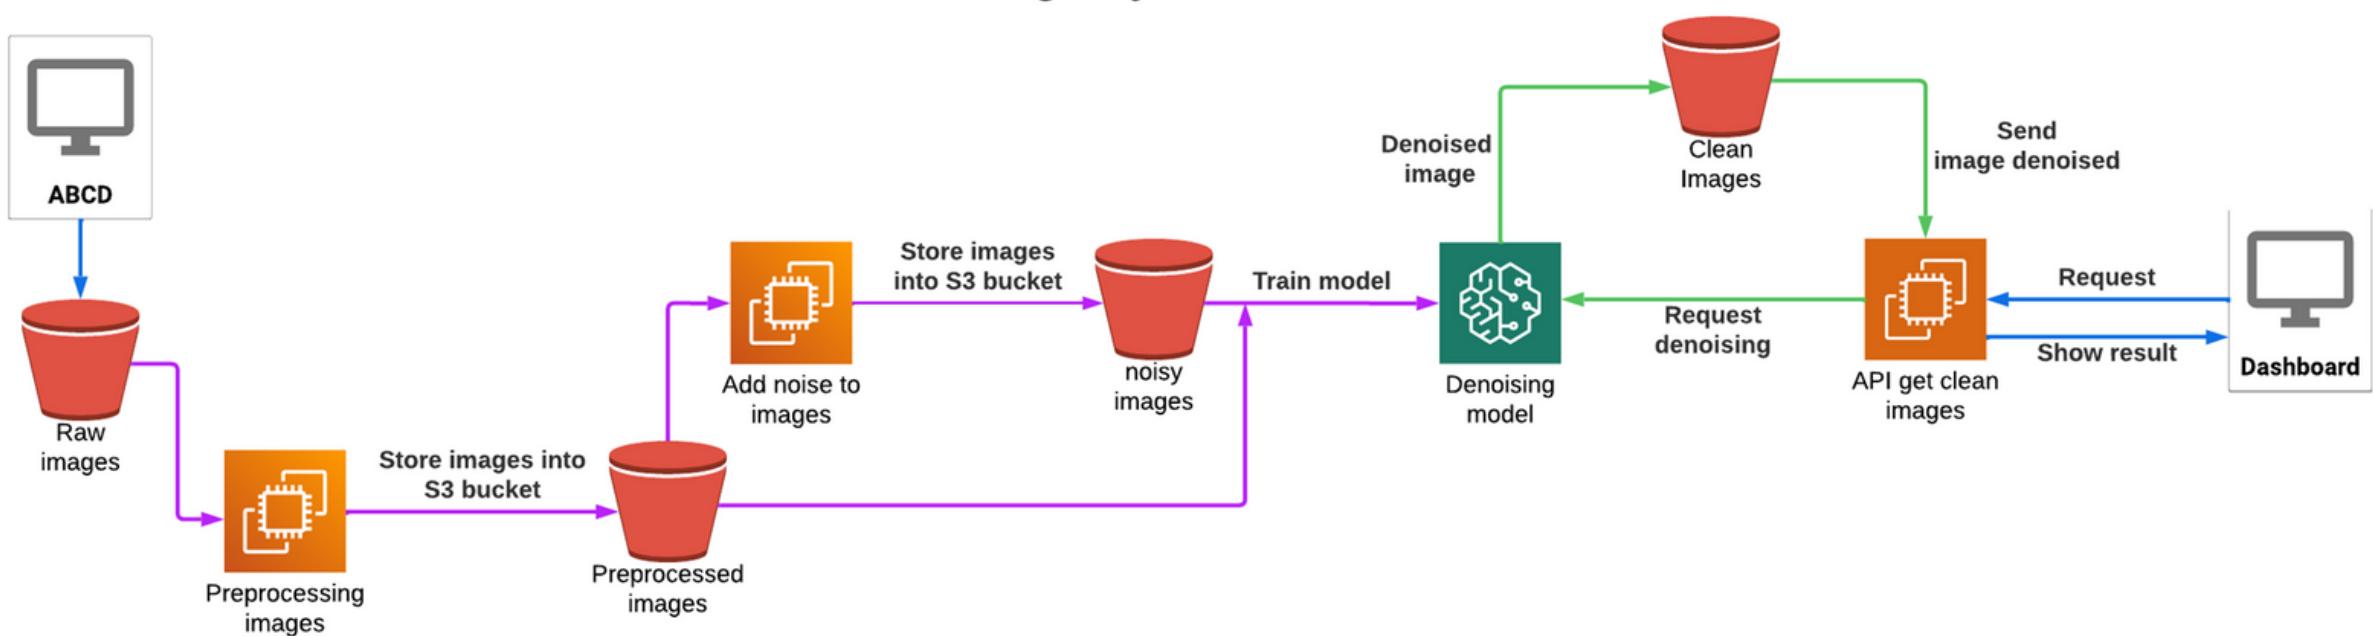
# Usuarios finales



Hospitales y laboratorios de México que realicen estudios de radiología.

# Arquitectura

Denoising Ray-x





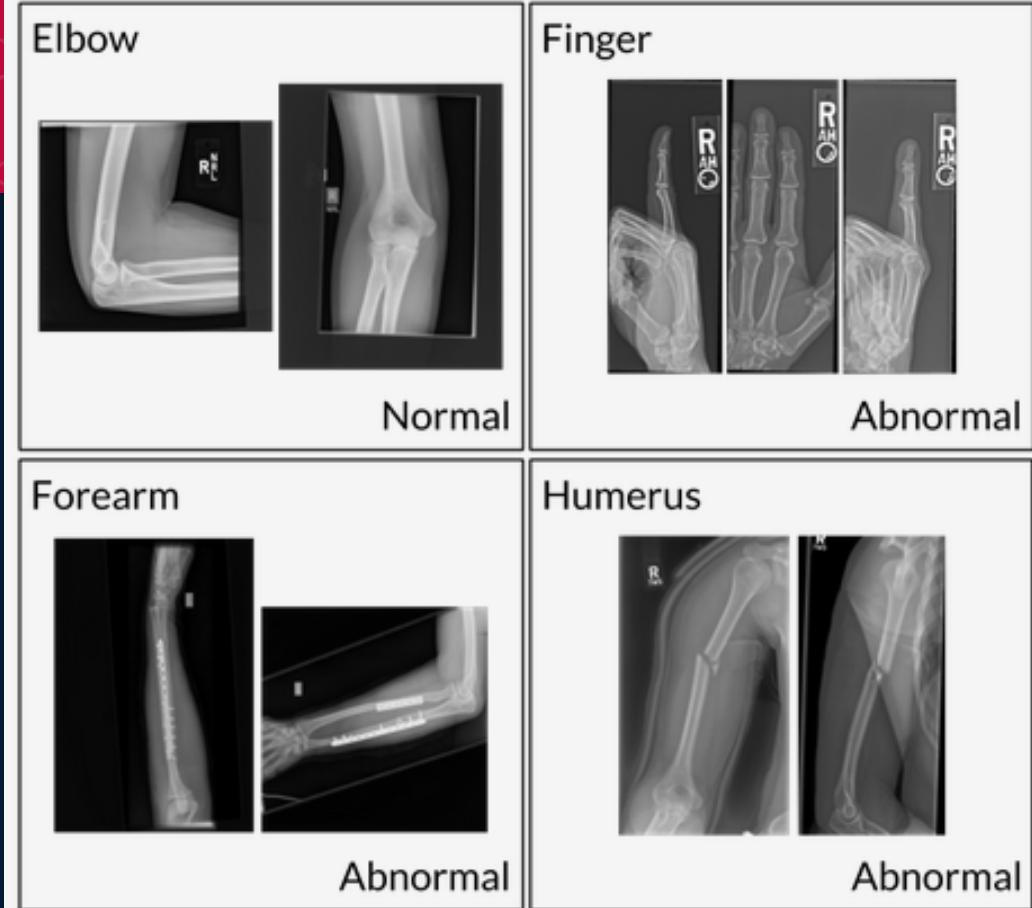
Bone X-Ray Deep Learning Competition

Fuente: Stanford Hospital

14,863 estudios de 12,173 pacientes

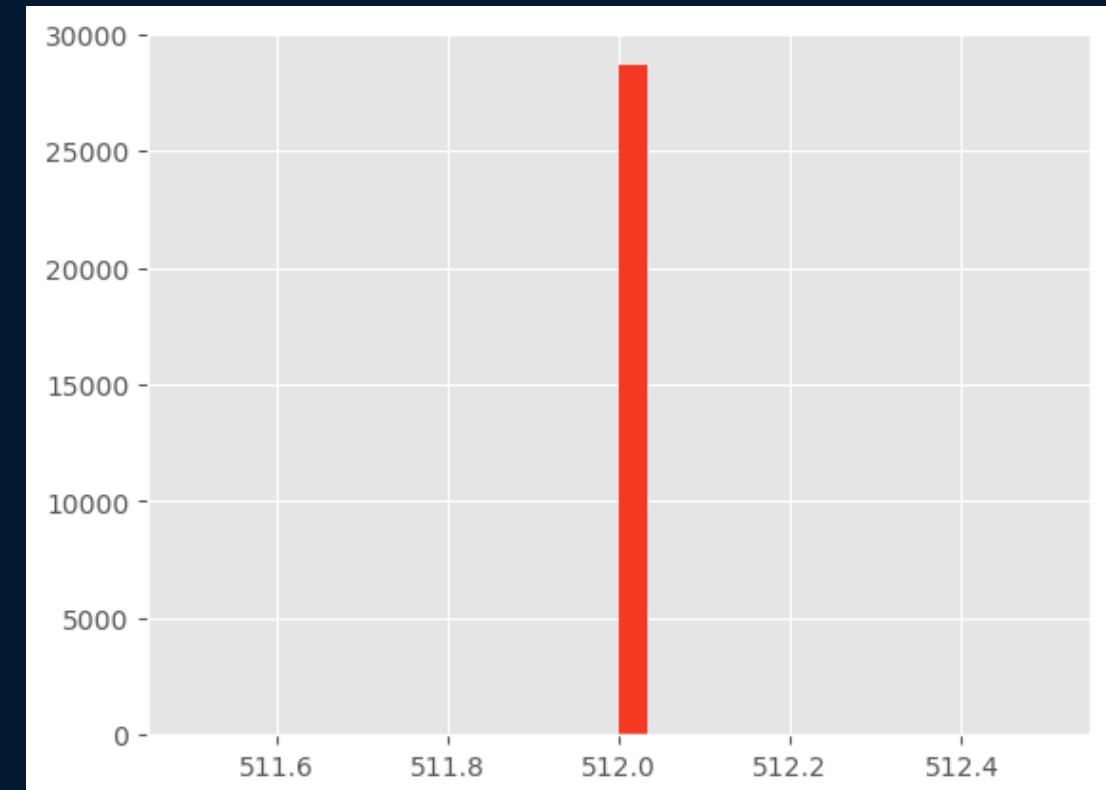
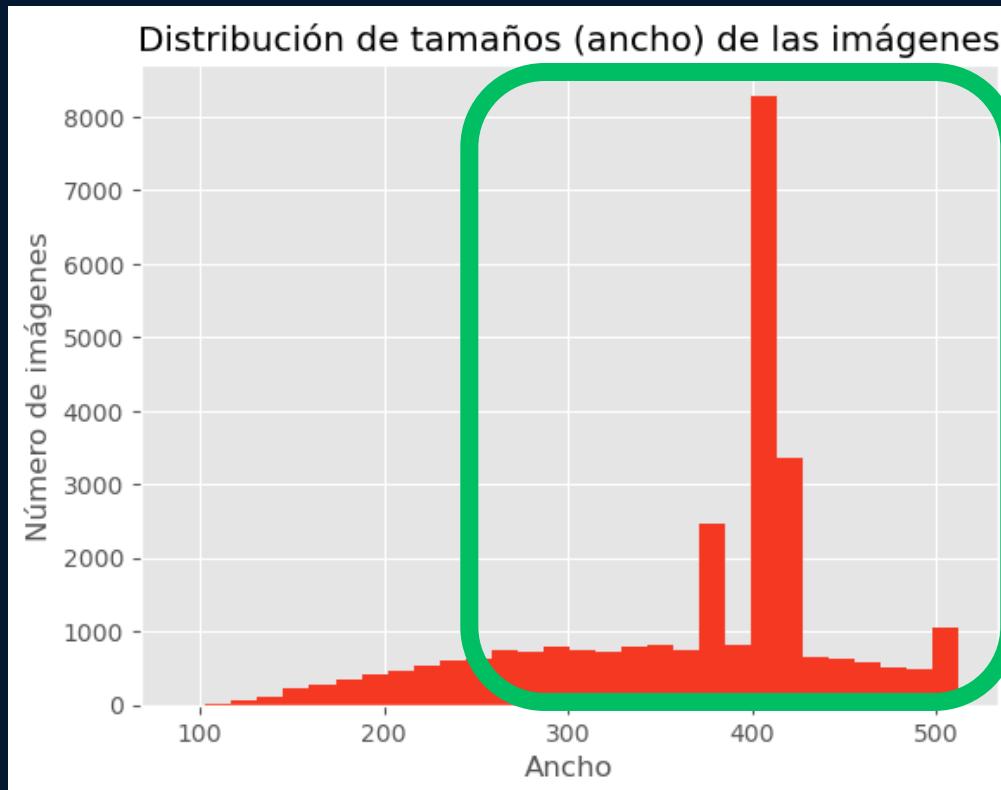
Tamaño = 40k

**90% entrenamiento - 10% prueba**



# Preprocesamiento

- **Eliminar imágenes con  $ppn < 60\%$**
- **Rotar las imágenes que cumplan  $h < w$**
- **Reescalamiento:  $h = 512$ ,  $w = 400$**



# Adición de ruido gaussiano



# Modelo autoencoder

# Arquitectura DnCNN

# LAYERS: 8 ENCODER - 8 DECODER

# PARAMS: 269,577

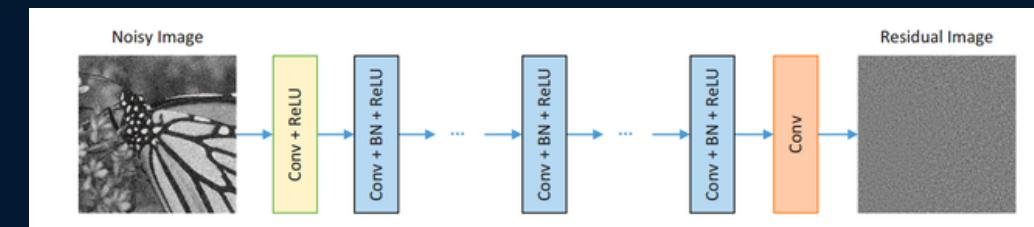
ACTIVATIONS: RELU

OPTIMIZATOR: ADAM

ÉPOCAS: 250

BATCH: 16

LOSS: MSE



# Demo



# Conclusiones

- **Trabajar con imágenes de radiografías es complicado por la calidad de cada imagen y de cada radiografía, además de que los valores RGB de las imágenes son pequeños.**
- **Trabajar con un proceso de Working Backwards permite tener las necesidades del cliente siempre en el foco principal.**
- **Un reescalamiento del tamaño de las imágenes tiene un efecto en el desempeño y en la complejidad de la solución.**

# Referencias

- Notas del curso Arquitectura de Datos 2023 del ITAM.
- Goodfellow, I., Bengio, Y., & Courville, A. (2016). Deep Learning. MIT Press.
- Bishop, C. M. (2006). *Pattern Recognition and Machine Learning (Information Science and Statistics)*. Berlin, Heidelberg: Springer-Verlag.

# Láminas adicionales

# Te gustan los retos profundos?

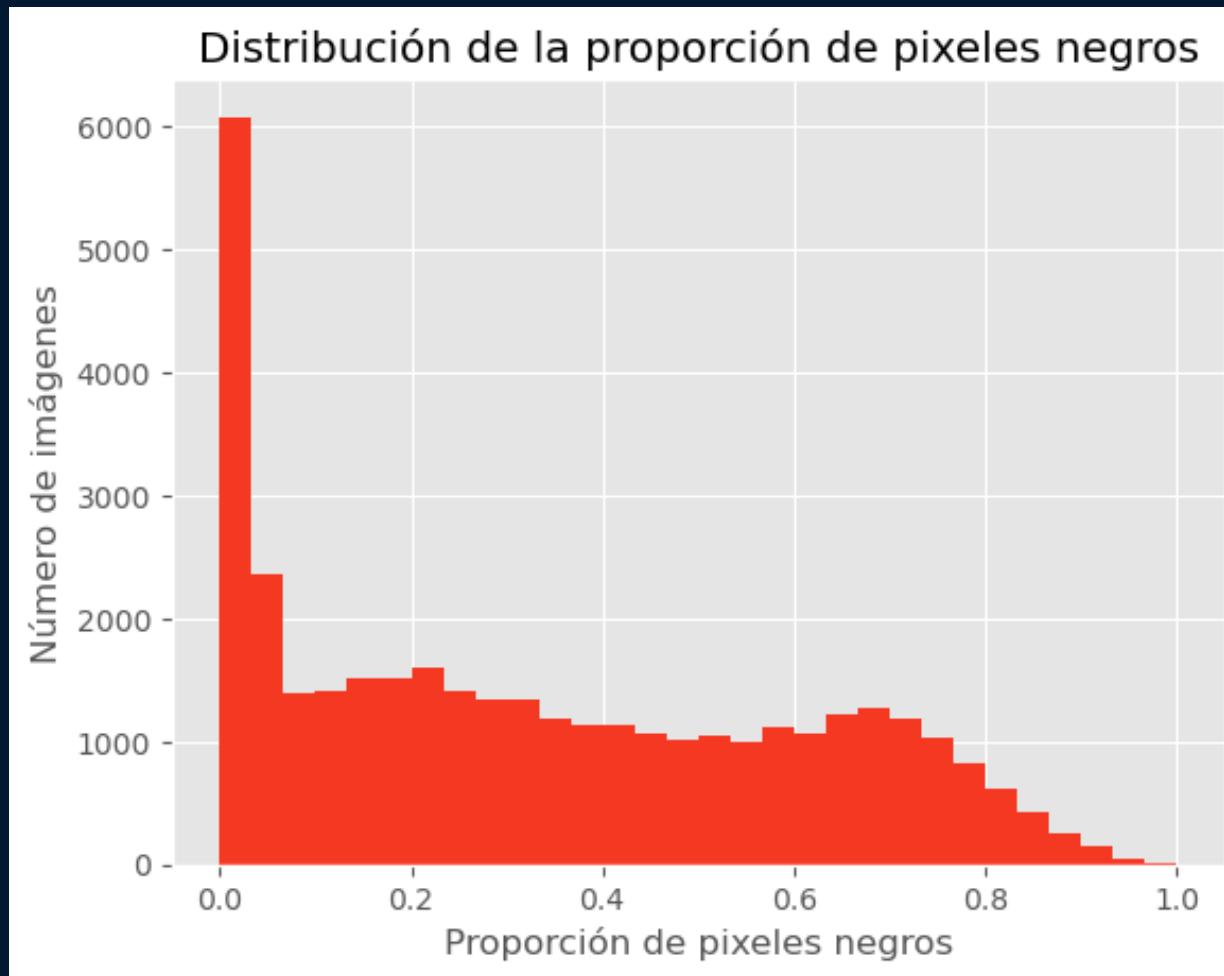
## Leaderboard

Will your model perform as well as radiologists in detecting abnormalities in musculoskeletal X-rays?

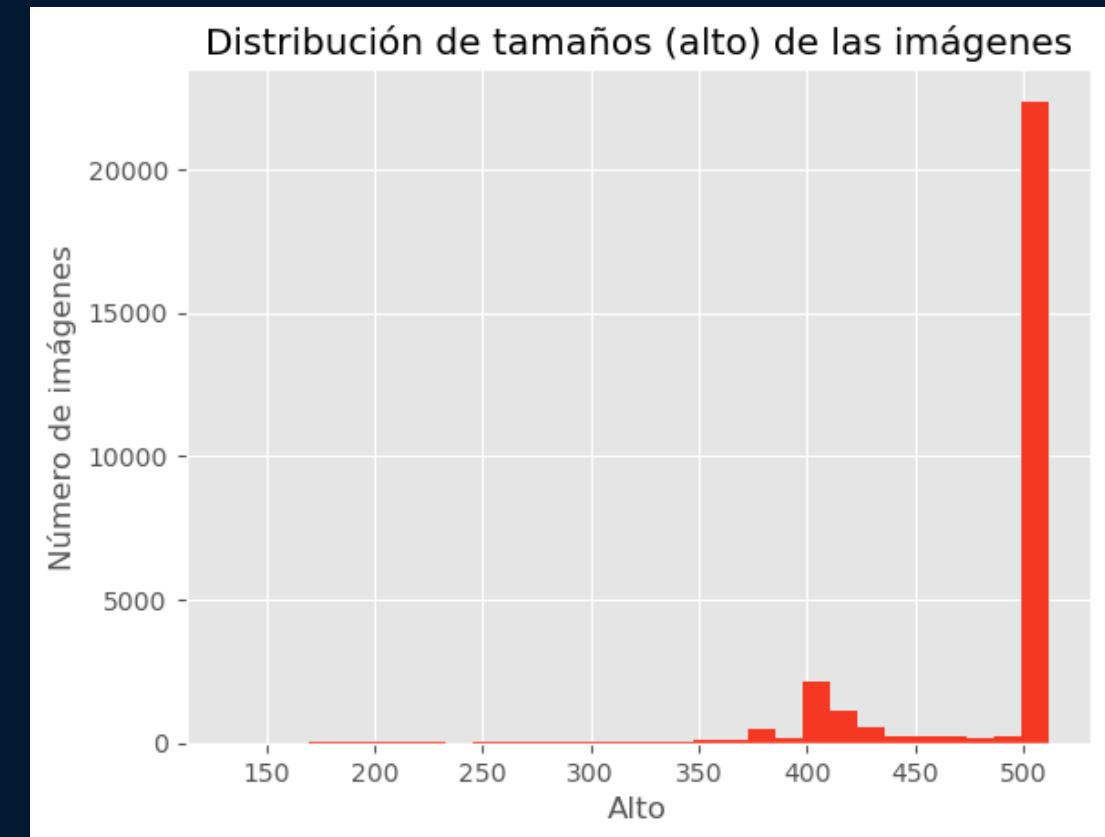
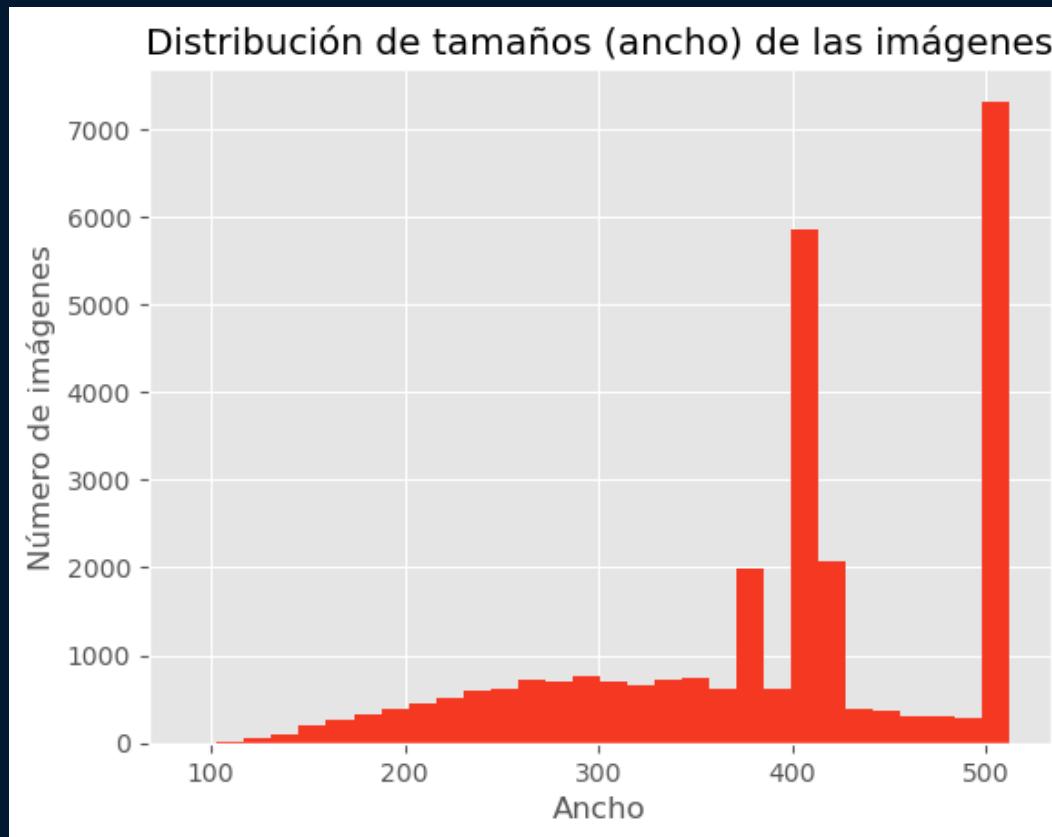
Rank	Date	Model	Kappa
		Best Radiologist Performance <i>Stanford University Rajpurkar &amp; Irvin et al., 17</i>	0.778
1	Nov 30, 2018	base-comb2-xuan-v3(ensemble) <i>jzhang Availink</i>	0.843
2	Nov 07, 2018	base-comb2-xuan(ensemble) <i>jzhang Availink</i>	0.834
3	Oct 06, 2018	muti_type (ensemble model) <i>SCU_MILAB</i>	0.833
4	Oct 02, 2018	base-comb4(ensemble) <i>jzhang Availink</i>	0.824
5	Nov 09, 2018	base-comb2-jun2(ensemble)	0.814
5	Nov 07, 2018	base-comb2-ping(ensemble)	0.814
6	Aug 22, 2018	base-comb3(ensemble)	0.805
7	Sep 14, 2018	double_res(ensemble model) <i>SCU_MILAB</i>	0.804



# Análisis exploratorio

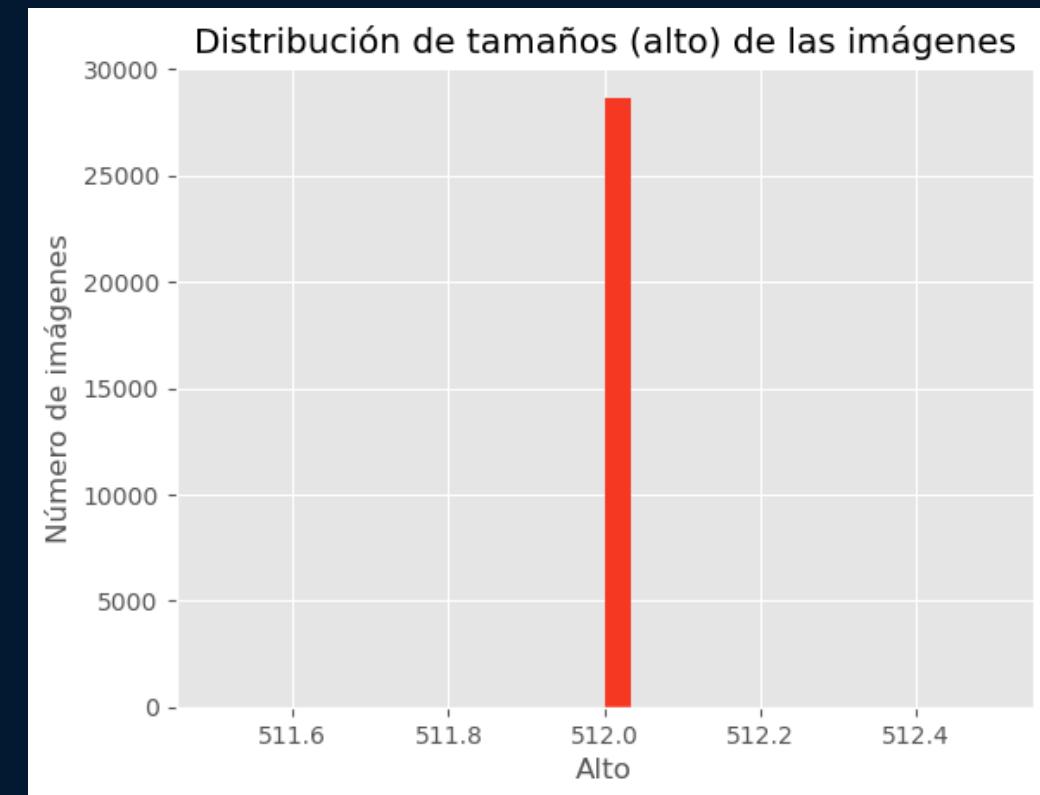
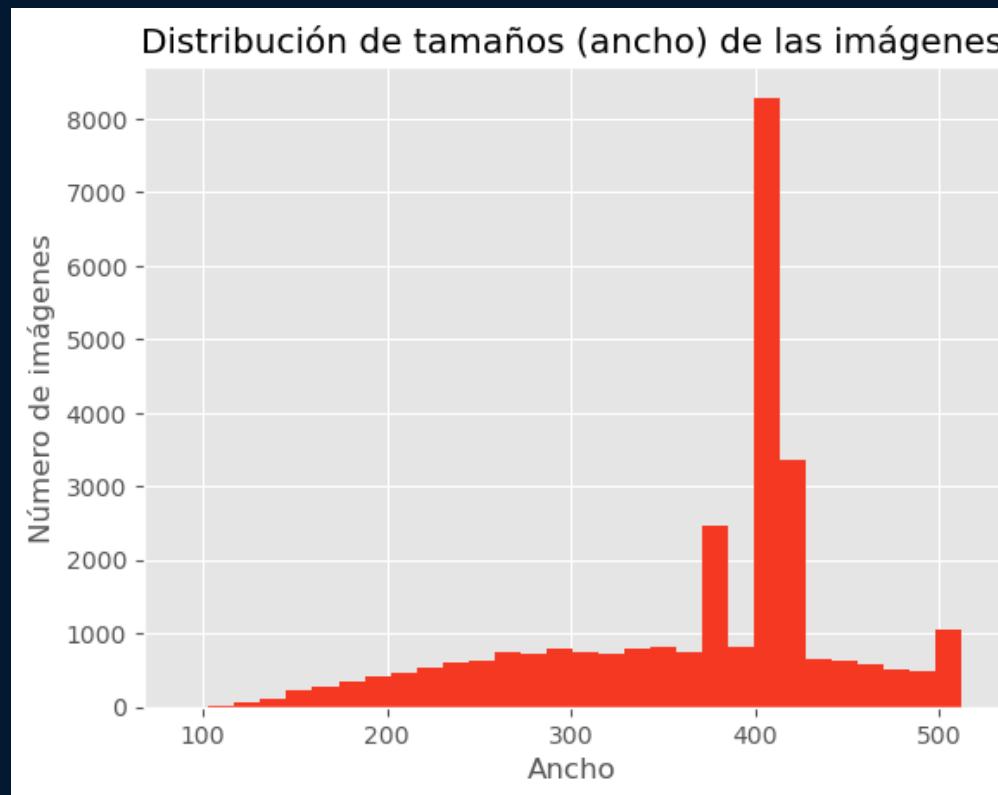


# Análisis exploratorio



# Preprocesamiento

- **Eliminar imágenes con  $ppn < 60\%$**
- **Rotar las imágenes que cumplan  $h < w$**



# Adición de ruido gaussiano



# IMPLEMENTACIÓN Y LIMITACIONES



# Solución

- **Imágenes de entrenamiento: 15,000**
- **Imágenes de prueba: 500**
- **Segundo reescalamiento:  $h = 64, w = 48$**

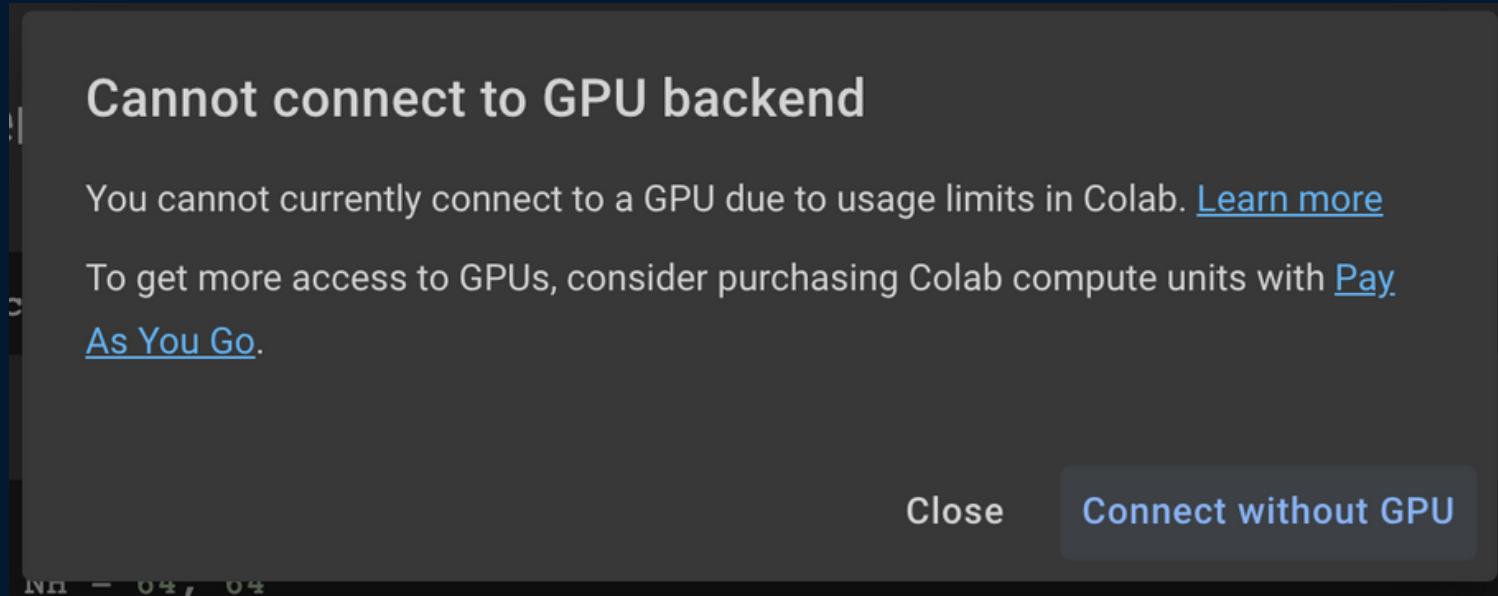


# Implementación

- **Imágenes de entrenamiento: 25,500~**
- **Imágenes de prueba: 2,000~**

colab

# Problemas de cómputo y memoria



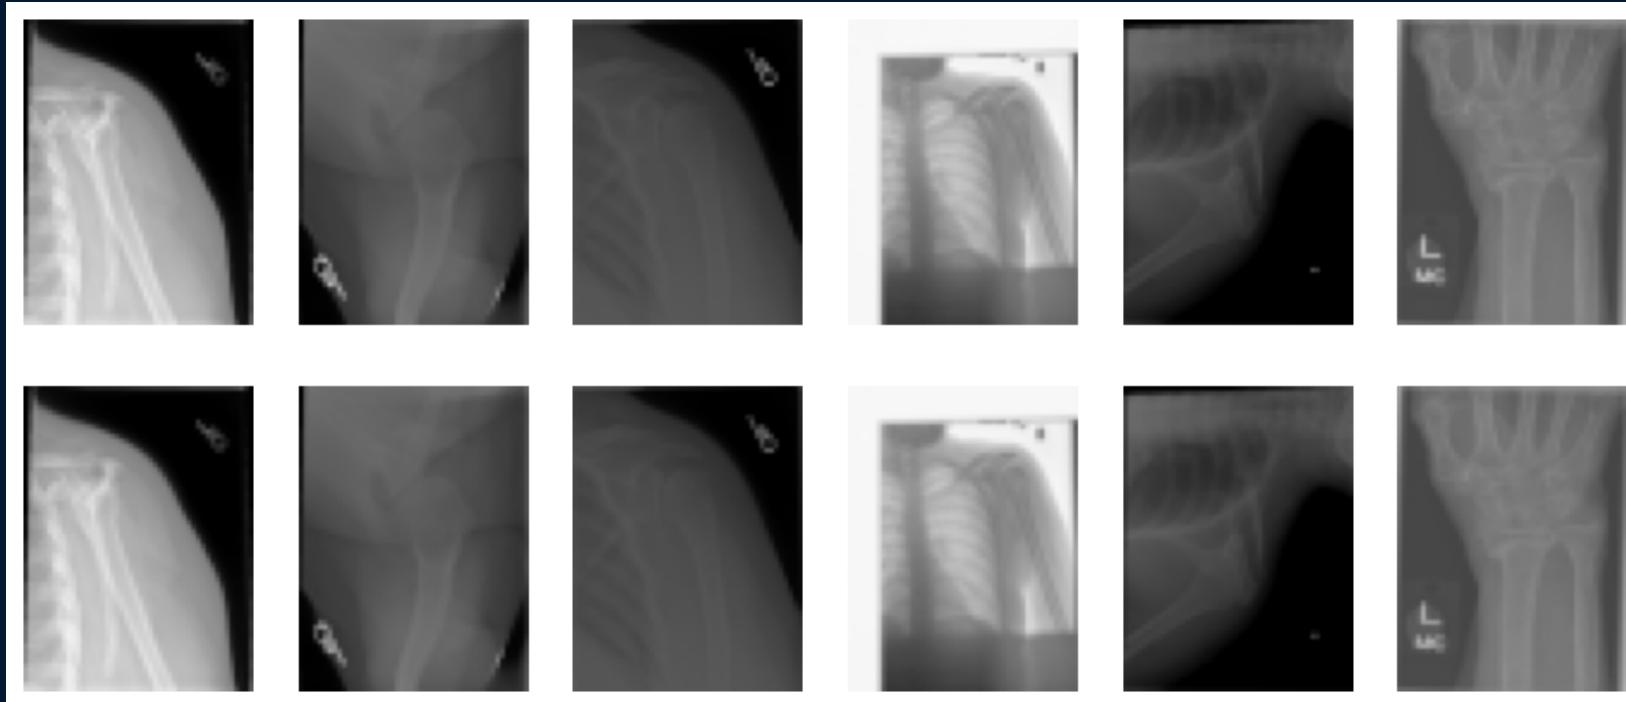
**MEJOR  
MODELO  
OBTENIDO**



# Resultados

**LOSS: 2.7031E-05**

**ACCURACY: 0.3372**



# COMPARACIÓN DE MODELOS



# Modelo autoencoder

**# CAPAS: 6 ENCODER - 6 DECODER**

**# PARÁMETROS: 333,955**

**ACTIVATIONS: RELU, ELU, SIGMOIDE**

**OPTIMIZADOR: ADAM**

**PÉRDIDA: MSQ**

**ÉPOCAS: 200**

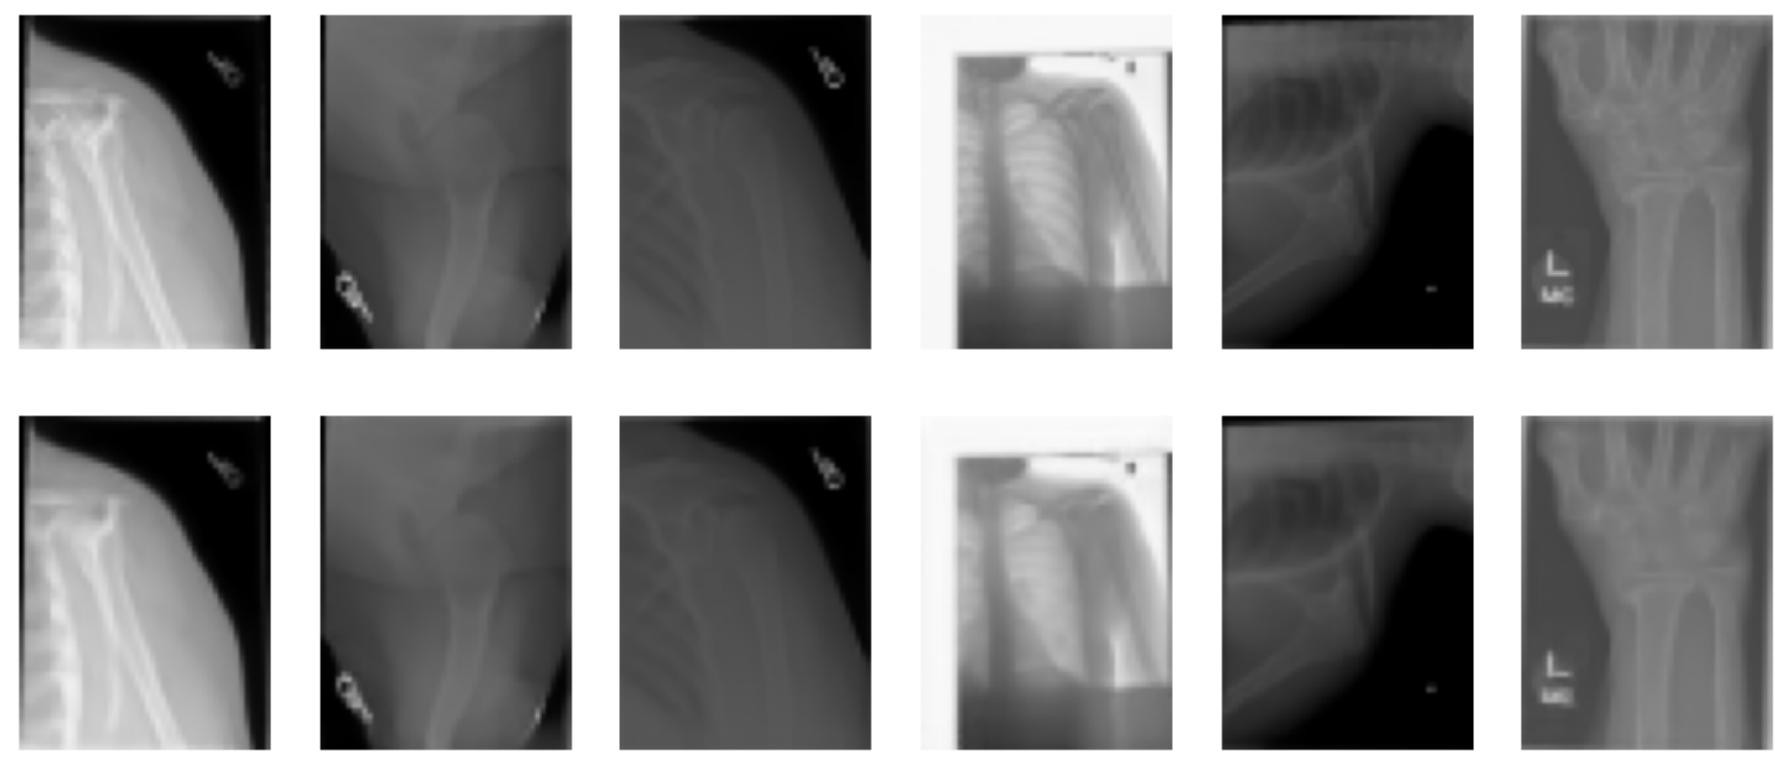
**TAMAÑO DE BATCH: 32**

**TIEMPO DE ENTRENAMIENTO: 45 MINUTOS**

# Resultados

**LOSS: 5.9301E-4**

**ACCURACY: 0.3012**



# Modelo más profundo

**# CAPAS: 11 ENCODER - 11 DECODER**

**# PARÁMETROS: 657,167**

**ACTIVATIONS: ELU, SIGMOIDE**

**OPTIMIZADOR: ADAM**

**PÉRDIDA: MSQ**

**ÉPOCAS: 250**

**TAMAÑO DE BATCH: 16**

**TIEMPO DE ENTRENAMIENTO: 4 HORAS~**

# Resultados

**LOSS: 5.0356E-4**

**ACCURACY: 0.3863**

